Análise - Olist V2

1. Contexto

Dataset: Brazilian E-Commerce Public Dataset by Olist

Processo de negócio: acompanhamento de pedidos de um marketplace, incluindo produtos, vendedores, pagamentos, frete, desempenho das entregas e avaliações dos clientes.

Ferramenta principal: SQL, Snowflake, dbt, Power BI e Git/Github

Objetivo de prática: construir um projeto de Analytics Engineering de ponta a ponta, desde a organização dos arquivos de origem no Snowflake até a disponibilização de modelos analíticos testados e de um dashboard no Power BI. A arquitetura utiliza as camadas RAW, STAGING, INTERMEDIATE e MARTS.

Pergunta principal *(O que quero descobrir)*: como o volume de pedidos e o valor dos itens variam entre produtos, períodos e regiões, e como o desempenho das entregas se relaciona com a experiência dos clientes?

2. Entendimento dos dados

Cada linha representa e granularidade dos modelos:

- `dim_customers`: Um cadastro de cliente associado ao pedido, identificado por customer_id.
- `dim_products:` Um produto, identificado por product_id.
- `dim_sellers:` Um vendedor, identificado por seller_id.
- `dim_geography:` Um prefixo de CEP, com localização geográfica consolidada.
- `fct_orders:` Um pedido, identificado por order_id.
- `fct_order_items:` Um item de um pedido, identificado pelo par (order_id, order_item_id).
- `fct_order_payments:` Uma sequência de pagamento de um pedido, identificada pelo par (order_id, payment_sequential).
- `fct_order_reviews:` Um registro de avaliação da origem; review_id não é necessariamente único.

Uma sequência de pagamento não representa necessariamente uma parcela. A quantidade de parcelas é uma informação do registro de pagamento.

Período: histórico aproximadamente entre 2016 e 2018. Os anos de 2016 e 2018 são incompletos e exigem cuidado nas comparações.

Unidade de análise: pedido para análises comerciais e logísticas; item do pedido para produtos, categorias, vendedores e frete; registro de avaliação para os indicadores de satisfação. Cliente, estado e mês são perspectivas de segmentação.

Fatos / eventos

- `fct_orders`: pedidos, status e datas do ciclo de compra e entrega.
- `fct_order_items`: produtos vendidos, vendedores, preço e frete dos itens.
- `fct_order_payments`: modalidades, parcelas e valores dos pagamentos.
- `fct_order_reviews`: notas, comentários e datas das avaliações.

Dimensões

- `dim_customers`: identificação e localização do cadastro associado ao pedido.
- `dim_products`: categorias e características dos produtos.
- `dim_sellers`: identificação e localização dos vendedores.
- `dim_geography`: localização consolidada por prefixo de CEP; permanece sem relacionamento ativo no modelo semântico atual.

O Power BI também utiliza `Dim_Calendario`, criada via DAX e relacionada à data da compra. Ela não é uma tabela física dos marts. A tabela `_Medidas` organiza os cálculos DAX.

Métricas principais

- **Pedidos entregues:** quantidade de pedidos com status `delivered`.
- **Valor dos itens entregues:** soma dos preços dos itens associados aos pedidos entregues.
- **Ticket médio dos itens entregues:** valor dos itens entregues dividido pela quantidade de pedidos entregues que possuem itens.
- **Valor do frete:** soma do frete dos itens no recorte analisado.
- **Participação do frete — definição proposta para esta análise:** frete dividido pela soma de itens e frete, usando a mesma população de pedidos.
- **Taxa de atraso:** pedidos entregues após a data prevista divididos pelos pedidos entregues com datas real e prevista disponíveis.
- **Tempo médio de entrega:** média do intervalo entre compra e entrega, considerando pedidos entregues com datas válidas.
- **Nota média das avaliações:** média das notas por registro de avaliação.

Qualidade e limitações iniciais

- O dataset é histórico e estático.
- `customer_id` e `customer_unique_id` têm significados diferentes: o segundo permite identificar o mesmo comprador entre pedidos.
- `review_id` pode se repetir e não deve ser tratado como chave única.
- Itens, pagamentos e avaliações possuem grãos diferentes. Antes de combiná-los no grão de pedido, é necessário agregar cada fato separadamente.
- Categorias sem tradução, comentários ausentes e datas não preenchidas precisam de tratamento explícito.
- A cobertura de prefixos de CEP não é completa; um enriquecimento geográfico não deve eliminar registros sem correspondência.

- Valor dos itens, frete e pagamentos são conceitos distintos. Nenhum deles representa automaticamente receita líquida.

3. Perguntas analíticas

1. Como evoluíram mensalmente os pedidos entregues, o valor dos itens entregues e o ticket médio dos itens entregues?
2. Quais categorias de produto e estados dos clientes concentraram maior valor de itens entregues e maior volume de pedidos?
3. Como o tempo médio de entrega e a taxa de atraso variaram entre os estados dos clientes?
4. Pedidos entregues com atraso apresentaram notas de avaliação diferentes dos pedidos entregues no prazo?
5. Em quais estados dos clientes o frete representou a maior parcela da soma de itens e frete dos pedidos entregues?

Hipóteses

- **H1:** o valor dos itens e o volume de pedidos estão concentrados em um conjunto reduzido de categorias e estados.
- **H2:** pedidos entregues com atraso apresentam notas de avaliação menores que os pedidos entregues no prazo.
- **H3:** estados com maior tempo médio de entrega apresentam maior participação do frete no valor de itens mais frete.

4. Análise

Pergunta 1 — Como os indicadores comerciais evoluíram mensalmente?

Evidência: a documentação do projeto registra 99.441 pedidos e R$ 13.591.643,70 em preços de itens no conjunto completo, considerando todos os status. O modelo possui calendário e medidas para analisar pedidos entregues, valor dos itens entregues e ticket médio. Os resultados mensais desse recorte ainda precisam ser consultados e registrados.

Interpretação: os totais gerais caracterizam o tamanho da base, mas não demonstram crescimento, queda ou sazonalidade. A conclusão temporal depende da série mensal validada, considerando os períodos incompletos de 2016 e 2018.

Pergunta 2 — Quais categorias e estados concentraram os resultados?

Evidência: o modelo permite segmentar os itens por categoria do produto e os pedidos por estado do cliente. Os rankings e as participações desses segmentos ainda não foram registrados como resultados validados na documentação consultada.

Interpretação: a hipótese de concentração permanece em aberto. Para avaliar sua intensidade, será necessário calcular a participação das principais categorias e estados, mantendo explícito o filtro de pedidos entregues.

Pergunta 3 — Como o desempenho das entregas variou entre os estados?

Evidência: o modelo possui medidas para tempo médio de entrega, pedidos entregues no prazo e pedidos atrasados. A avaliação de pontualidade considera pedidos com status `delivered` e datas real e prevista disponíveis. Os resultados por estado ainda precisam ser calculados e registrados.

Interpretação: diferenças entre estados devem ser avaliadas junto com o volume de pedidos e a disponibilidade de datas. Sem esses resultados, não é possível identificar quais estados tiveram melhor ou pior desempenho.

Pergunta 4 — Atrasos estiveram associados a notas diferentes?

Evidência: a documentação registra 99.224 avaliações no conjunto completo. As tabelas permitem relacionar avaliações aos pedidos e comparar a data real de entrega com a previsão. A comparação das notas entre pedidos atrasados e pontuais ainda não foi validada.

Interpretação: ainda não é possível confirmar a hipótese de notas menores nos pedidos atrasados. A análise deverá definir como tratar pedidos com mais de uma avaliação e apresentar a quantidade de pedidos de cada grupo. Mesmo que uma diferença seja encontrada, ela indicará associação, não causalidade.

Pergunta 5 — Em quais estados o frete teve maior participação?

Evidência: no conjunto completo, a documentação registra R$ 2.251.909,54 de frete e R$ 13.591.643,70 em preços de itens. Esses totais incluem todos os status. A participação do frete por estado, restrita aos pedidos entregues, ainda precisa ser calculada.

Interpretação: o frete representa uma componente relevante do valor associado aos pedidos, mas os totais gerais não identificam os estados com maior participação. A comparação deverá usar a mesma definição e a mesma população em todos os estados.

5. Conclusões

Principais descobertas

1. **A base analítica preserva os diferentes grãos do negócio.** O projeto documenta 99.441 pedidos, 112.650 itens, 103.886 pagamentos e 99.224 avaliações, organizados em quatro fatos e quatro dimensões. A validação registrada em 22/10/2026 apresentou 56 testes dbt aprovados.
2. **Preços, frete e pagamentos não são intercambiáveis.** No conjunto completo, os pagamentos somam R$ 16.008.872,12 e excedem a soma de itens e frete em R$ 165.318,88. Essa diferença exige uma definição de negócio antes de tratar os valores como receita ou faturamento.
3. **A combinação direta dos fatos pode distorcer os indicadores.** A documentação registra uma simulação em que o join sem agregação prévia elevou a soma dos pagamentos para R$ 20.416.842,54. A diferença decorre da multiplicação de linhas, e não de vendas adicionais.

Resposta à pergunta principal

Até esta etapa, o projeto disponibilizou uma base organizada, testada e com definições de indicadores para investigar vendas, logística e satisfação. Entretanto, os resultados por mês, categoria e estado, assim como a comparação entre atraso e nota, ainda precisam ser validados quantitativamente. Portanto, ainda não há evidência suficiente para concluir quais segmentos se destacam ou se pedidos atrasados recebem avaliações menores.

Limitações

- O histórico é estático e contém anos incompletos.
- Os totais gerais apresentados não correspondem necessariamente ao recorte de pedidos entregues.
- Valor dos itens e pagamentos não equivalem automaticamente a receita líquida.
- A existência de medidas DAX não substitui a validação de seus resultados após a atualização dos dados.
- Avaliações repetidas por pedido exigem um critério de análise explícito.
- Uma associação entre atraso e nota não demonstraria, por si só, causalidade.

6. O que pratiquei

Técnicas:

- Organização de dados em camadas RAW, STAGING, INTERMEDIATE e MARTS.
- Limpeza, padronização e transformação com SQL.
- Modelagem dimensional e definição dos grãos.
- Definição de chaves e relacionamentos lógicos.
- Testes de unicidade, preenchimento e integridade referencial com dbt.
- Reconciliação de contagens e valores entre fatos.
- Modelagem semântica, medidas DAX e inteligência temporal.
- Construção de dashboard com páginas comerciais, de produtos e vendedores e de logística e satisfação.
- Documentação da arquitetura, dos indicadores e das limitações.
- Versionamento do projeto e do modelo Power BI.

Ferramentas/recursos:

- SQL, Snowflake, dbt, Power BI, DAX, Git/GitHub, formato PBIP/TMDL e DrawDB.

Principal aprendizado:

Uma análise confiável começa pela definição do que cada linha representa e de quais registros entram em cada indicador. Tabelas relacionadas podem representar eventos e grãos diferentes; combiná-las sem esse cuidado pode duplicar valores e produzir conclusões incorretas. Também aprendi a distinguir a implementação de uma medida, a validação do seu resultado e a interpretação de negócio.